

Implementación Manual de Regresión Logística para la Clasificación de Sitios Web de Phishing

Aron Cortez Villafuerte

Inteligencia artificial avanzada para la ciencia de datos I

Instituto Tecnológico y de Estudios Superiores de Monterrey

Querétaro, México

Abstract— Este proyecto busca implementar y analizar un modelo de regresión logística para un problema de clasificación. La implementación se desarrolla de manera manual, sin utilizar bibliotecas o frameworks de aprendizaje automático, con el objetivo de comprender y aplicar directamente los componentes principales de la regresión logística, incluyendo la función sigmoide, la función de costo basada en entropía cruzada y el algoritmo de descenso de gradiente. Para esta implementación se utiliza un conjunto de datos relacionado con la detección de sitios web de phishing, donde el objetivo es clasificar cada instancia de acuerdo con las características proporcionadas en el dataset. El modelo se evalúa utilizando conjuntos de entrenamiento, validación y prueba, mediante la función de pérdida, Accuracy, Precision y la matriz de confusión. Los resultados obtenidos fueron similares entre Train, Validation y Test, con una Accuracy de 92.02 %, 92.67 % y 92.40 %, respectivamente. A partir de estos resultados y de la evolución de la función de costo, se realiza un diagnóstico cualitativo de bias bajo, varianza baja y ajuste adecuado.

Keywords— Machine Learning, Regresión Logística, Clasificación, Gradiente Descendente, Entropía Cruzada, Train/Test/Validation, Bias, Varianza, Overfitting, Underfitting, Python.

I. INTRODUCCIÓN

A. Contexto general

El aprendizaje automático permite analizar conjuntos de datos con el objetivo de identificar patrones y generar predicciones a partir de la información disponible. Dentro del aprendizaje supervisado, existen problemas de clasificación, donde se busca asignar una instancia a una categoría determinada.

La aplicación de este proyecto se relaciona con la detección de sitios web de phishing. El phishing consiste en el uso de páginas o direcciones web que buscan aparentar ser sitios legítimos con el propósito de engañar al usuario. El conjunto de datos utilizado contiene distintas características asociadas a la estructura y comportamiento de una página web, como el uso de una dirección IP, la longitud de la URL, la presencia de determinados símbolos, el uso de HTTPS, el registro DNS y el tráfico del sitio. Estas características permiten plantear un problema de clasificación cuyo objetivo es determinar si una instancia corresponde a un sitio legítimo o a un sitio de phishing. El desarrollo de un modelo de este tipo puede ser útil para automatizar la identificación de patrones asociados con páginas potencialmente fraudulentas.

B. Objetivo

El objetivo de este proyecto es implementar manualmente un modelo de regresión logística para clasificar sitios web como legítimos o phishing, sin utilizar una biblioteca o framework de aprendizaje automático.

Además de realizar predicciones con el modelo, se evaluará su comportamiento utilizando conjuntos de entrenamiento, validación y prueba. Posteriormente, se realizará un análisis de su desempeño, considerando de manera cualitativa su grado de sesgo, varianza y nivel de ajuste.

II. DESCRIPCIÓN Y PREPARACIÓN DE LOS DATOS

A. Dataset Phishing Websites

1. Fuente y estructura del conjunto de datos

El conjunto de datos utilizado en este proyecto corresponde a Phishing Websites, extraído del repositorio abierto de UCI Machine Learning [1], cuyo propósito es representar diferentes características que pueden encontrarse en sitios web legítimos o utilizados para phishing. A diferencia de un conjunto de datos que contiene directamente el texto o la dirección completa de cada página, este dataset representa cada instancia mediante características previamente extraídas de la URL, del contenido del sitio y de información asociada con el dominio. De esta forma, cada registro puede ser utilizado como entrada para un modelo de clasificación.

El archivo utilizado para el proyecto contiene 11,055 instancias. Cada una de ellas está formada por 30 características predictoras (features, x) y una variable de salida denominada Result (target, y). Los atributos se encuentran representados mediante valores discretos, principalmente -1, 0 y 1, pero analizando los datos se observa que no todas las variables utilizan los tres valores, sino que, por ejemplo, la variable having_IP_Address únicamente puede tomar los valores -1 y 1, ya que hay o no hay una IP, mientras que variables como URL_Length, having_Sub_Domain y SSLfinal_State también pueden tomar el valor 0. La variable Result, por su parte, contiene únicamente dos posibles valores, -1 y 1, por lo que el abordaje será tratado como una clasificación binaria.

Los features de este dataset son muy interesantes, ya que describen los elementos principales que usualmente se distinguen a simple vista en una página falsa y también incluyen otros datos que son más difíciles de identificar a simple vista. Entre ellos se encuentran el uso de una dirección IP en lugar de un nombre de dominio, la longitud de la URL, el uso de servicios para acortar direcciones, la presencia del símbolo @, la existencia de redireccionamientos y el uso de múltiples subdominios. El documento asociado al dataset [2] explica que estas características fueron seleccionadas debido a que determinados patrones dentro de una URL pueden encontrarse con mayor frecuencia en sitios de phishing.

El conjunto de datos también incluye características relacionadas con el dominio y con la presencia del sitio en Internet, como la edad del dominio, la existencia de un registro DNS, el tráfico web, el PageRank, la presencia del sitio dentro del índice de Google y la cantidad de enlaces que apuntan hacia la página. Estas variables permiten que la clasificación no dependa únicamente de la estructura de la URL, sino también de otros elementos relacionados con el comportamiento y reconocimiento del sitio.

2. Clasificación de las variables

TABLA I. CLASIFICACIÓN DE LAS VARIABLES

Variable	Valor que toma	Descripción
having_IP_Address	-1,1	Indica si la URL utiliza una dirección IP en lugar de un nombre de dominio.
URL_Length	-1,0,1	Clasifica la URL de acuerdo con su longitud. URLs excesivamente largas pueden utilizarse para ocultar partes sospechosas de la dirección.
Shortining_Service	-1,1	Indica el uso de servicios de acortamiento de URL, los cuales redirigen una dirección corta hacia otra página.
having_At_Symbol	-1,1	Indica la presencia del símbolo @ dentro de la URL.
double_slash_redirecting	-1,1	Evalúa la presencia de // en una posición que pueda indicar un redireccionamiento dentro de la URL.
Prefix_Suffix	-1,1	Indica la presencia de prefijos o sufijos separados mediante guiones en el dominio.
having_Sub_Domain	-1,0,1	Representa la existencia y cantidad de subdominios dentro de la dirección.
SSLfinal_State	-1,0,1	Representa el estado relacionado con HTTPS y el certificado utilizado por el sitio.
Domain_registration_length	-1,1	Representa la duración del registro del dominio.
Favicon	-1,1	Evalúa si el favicon utilizado por la página pertenece al mismo dominio.
port	-1,1	Representa el uso de puertos considerados apropiados o no apropiados para los servicios web.
HTTPS_token	-1,1	Indica la aparición del término HTTPS dentro de la parte correspondiente al dominio de la URL.
Request_URL	-1,1	Evalúa si objetos externos de la página, como imágenes, videos o sonidos, son cargados desde el mismo dominio o desde dominios diferentes.
URL_of_Anchor	-1,0,1	Evalúa los enlaces incluidos en etiquetas <a> y su relación con el dominio de la página.
Links_in_tags	-1,0,1	Evalúa los enlaces encontrados dentro de etiquetas <Meta>, <Script> y <Link>.
SFH	-1,0,1	Representa el comportamiento del Server Form Handler utilizado para procesar información introducida en formularios.
Submitting_to_email	-1,1	Indica si la información enviada mediante un formulario es redirigida hacia una dirección de correo electrónico.
Abnormal_URL	-1,1	Evalúa si la identidad registrada del sitio guarda relación con la dirección URL.
Redirect	0,1	Representa la existencia o cantidad de redireccionamientos realizados por el sitio.
on_mouseover	-1,1	Indica el uso del evento onMouseOver para modificar información mostrada al usuario, como la dirección presentada en la barra de estado.
RightClick	-1,1	Indica si la página deshabilita la función de clic derecho mediante JavaScript.
popUpWidnow	-1,1	Representa el uso de ventanas emergentes, particularmente cuando estas solicitan información al usuario.

Variable	Valor que toma	Descripción
Iframe	-1,1	Indica el uso de elementos iframe, los cuales pueden utilizarse para mostrar contenido proveniente de otra página.
age_of_domain	-1,1	Representa la antigüedad del dominio.
DNSRecord	-1,1	Indica la existencia de información correspondiente al dominio dentro del registro DNS.
web_traffic	-1,0,1	Representa el nivel de tráfico o reconocimiento del sitio web.
Page_Rank	-1,1	Representa el PageRank asociado con la página web.
Google_Index	-1,1	Indica si el sitio se encuentra incluido dentro del índice de Google.
Links_pointing_to_page	-1,0,1	Clasifica el sitio según la cantidad de enlaces externos que apuntan hacia la página.
Statistical_report	-1,1	Representa información obtenida a partir de reportes estadísticos relacionados con dominios o direcciones IP asociadas al phishing.
Result (TARGET)	-1,1	Clase final que será utilizada como etiqueta para entrenar y evaluar el modelo de clasificación.

3. Revisión inicial de datos

Antes de realizar el entrenamiento del modelo se llevó a cabo una revisión inicial del conjunto de datos con el propósito de identificar posibles problemas que pudieran afectar el proceso de aprendizaje. Todas las observaciones presentan el mismo número de atributos, por lo que la estructura del dataset se mantiene consistente a lo largo de todos los registros.

Posteriormente, se realizó una búsqueda de valores faltantes dentro de todas las columnas del conjunto de datos. No se identificaron valores nulos ni registros representados mediante el símbolo "?". Es importante señalar que los valores -1, 0 y 1 observados en las variables forman parte de la codificación original de los atributos y, por lo tanto, no deben ser considerados como datos faltantes. Algunas variables únicamente utilizan dos posibles valores, mientras que otras emplean los tres niveles como categorías válidas dentro del dataset.

TABLA II. RESUMEN DE LA REVISIÓN INICIAL DEL DATASET

Elemento revisado	Resultado
Número de instancias	11,055
Número de features	30
Variable objetivo	Result
Número de clases	2
Valores de Result	-1, 1
Valores faltantes	0
Registros repetidos	5,206
Clase -1	4,898
Clase 1	6,157

4. Distribución de la variable objetivo

Se realizó una gráfica de distribución para entender mejor los resultados que tenemos en nuestro target y observar si tenemos alguna distribución extraña que afecte los datos.




Fig. 1. Distribución de las clases de la variable objetivo Result.

Como se observa en la Figura 1, existe una mayor cantidad de observaciones pertenecientes a la clase 1, pero no de forma exagerada; concluimos que ambas categorías mantienen una presencia considerable dentro del conjunto de datos. La diferencia entre ambas clases no impide que el modelo disponga de una cantidad importante de ejemplos correspondientes a cada una de ellas. Por esta razón, se decidió conservar la distribución original del dataset y no modificar artificialmente la cantidad de observaciones de ninguna de las dos clases.

5. Revisión de registros repetidos

Como parte del análisis de calidad de los datos, se realizó una búsqueda de observaciones que presentaran exactamente los mismos valores en las 30 características predictoras y en la variable objetivo. Esta revisión permitió identificar 5,206 registros que repetían una combinación completa previamente encontrada dentro del conjunto de datos.

A pesar de esta cantidad, los registros no fueron eliminados automáticamente. El dataset utilizado no contiene una dirección URL ni un identificador único que permita diferenciar cada página web de manera individual; únicamente se encuentran disponibles las características previamente extraídas y codificadas. Debido a que la mayoría de las variables utiliza un número reducido de categorías, diferentes sitios web pueden presentar exactamente la misma combinación de valores sin representar necesariamente una duplicación incorrecta de la información.

Como revisión adicional, se analizaron las combinaciones de las 30 variables predictoras sin considerar inicialmente la etiqueta Result. Se encontraron 64 combinaciones de características que aparecen asociadas a más de una clase, lo que demuestra que una misma representación de features puede encontrarse vinculada con resultados diferentes dentro del dataset.

Por esta razón, eliminar todas las filas repetidas únicamente con base en la igualdad de sus valores podría ocasionar la eliminación de observaciones válidas y modificar la distribución original de los datos, lo que inicialmente era lo que queríamos conservar y con esta conclusión vamos a continuar con el desarrollo del proyecto.

6. Preparación de los datos para el modelo

Una vez terminada la revisión inicial del conjunto de datos, se prepararon las variables que serán utilizadas durante el entrenamiento del modelo de regresión logística. En aprendizaje supervisado, cada instancia contiene un conjunto de características o features y una etiqueta conocida que representa el resultado real que el modelo debe aprender a predecir. En este caso, las 30 características predictoras fueron utilizadas como variables de entrada, mientras que Result se definió como la variable objetivo del problema. Esta organización corresponde a la estructura de features y labels utilizada para los problemas de clasificación revisados durante el módulo.

Para facilitar su uso dentro de la implementación de regresión logística, la variable Result, codificada originalmente mediante los valores -1 y 1, fue transformada a las clases 0 y 1. Las observaciones con valor -1 fueron representadas como 0, mientras que aquellas con valor 1 conservaron su valor original. Esta modificación no altera la clase a la que pertenece cada instancia ni cambia la distribución del conjunto de datos; únicamente adapta la representación de la etiqueta al funcionamiento del modelo.

Esta transformación es necesaria debido a que la regresión logística utiliza una función de activación sigmoide para generar valores dentro del intervalo de 0 a 1. Posteriormente, estas salidas son comparadas con las etiquetas reales durante el cálculo de la función de costo y se utilizan para determinar la clase predicha. Dentro del módulo, la regresión logística se estudia precisamente a partir de su función de hipótesis, función de activación, función de costo y posterior optimización mediante descenso de gradiente.

Después de realizar esta recodificación, se separaron los datos en dos componentes. Por una parte, X contiene las 30 características utilizadas como entrada del modelo; por otra, Y contiene únicamente la variable Result, es decir, la clase correcta correspondiente a cada observación. De esta manera, durante el entrenamiento el modelo utilizará las características de X para generar una predicción y la comparará posteriormente con el valor real almacenado en Y.

La preparación final mantuvo las 11,055 observaciones originales, sin eliminar registros ni modificar las características del dataset.

7. División del conjunto de datos

Para poder evaluar el comportamiento del modelo sobre observaciones diferentes a las utilizadas durante su entrenamiento, el conjunto de datos fue dividido en tres subconjuntos: entrenamiento, validación y prueba. La división se realizó utilizando aproximadamente el 60 % de las instancias para entrenamiento, 20 % para validación y 20 % para prueba.

Antes de realizar la separación se aleatorizaron los índices de las observaciones. Además, se utilizó una semilla fija para mantener la misma división entre ejecuciones y permitir que los resultados obtenidos posteriormente puedan reproducirse bajo las mismas condiciones.

El conjunto de entrenamiento será utilizado directamente por la regresión logística para aprender sus parámetros.

Durante este proceso, las observaciones de entrenamiento se emplearán para generar predicciones, calcular la función de costo y determinar el gradiente utilizado para actualizar los pesos del modelo. Por esta razón, este subconjunto participa directamente en el proceso de aprendizaje.

El conjunto de validación se mantuvo separado del cálculo de los pesos y se utilizó para observar el comportamiento del modelo durante el entrenamiento. De esta forma fue posible comparar su función de costo con la obtenida en Train sin recurrir todavía al conjunto de prueba.

Finalmente, el conjunto de prueba se utilizará una vez terminado el entrenamiento y seleccionado el modelo. Este subconjunto permitirá medir el desempeño final sobre observaciones que no fueron utilizadas directamente para aprender los parámetros ni para escoger los hiperparámetros. Esta separación permitirá posteriormente analizar la capacidad de generalización del modelo y comparar el comportamiento obtenido entre entrenamiento, validación y prueba.

III. MODELO DE CLASIFICACIÓN SIN FRAMEWORK

A. Regresión logística

Para resolver el problema de clasificación de sitios web se seleccionó un modelo de regresión logística, ya que la variable objetivo contiene únicamente dos posibles clases. A diferencia de una regresión lineal, la salida del modelo debe transformarse para poder utilizarse como una predicción de clasificación. La regresión logística realiza esta transformación mediante una función sigmoide, cuya salida se encuentra entre 0 y 1.

La implementación se desarrollará de manera manual, sin utilizar bibliotecas de aprendizaje automático que contengan el algoritmo previamente construido. El modelo estará compuesto por los elementos revisados durante el módulo: función de hipótesis, función de activación, función de costo y optimización mediante descenso de gradiente.

En este caso, las 30 características del dataset funcionan como entradas del modelo. Cada una participa en la predicción mediante un peso que será modificado durante el entrenamiento.

B. Función de hipótesis

El primer cálculo realizado por el modelo consiste en combinar las características de una observación con sus respectivos pesos. A esta combinación se agrega un término de sesgo b .

$$z = Xw + b$$

donde “X” representa las características de entrada, “w” los pesos asociados a dichas características y “b” el término de sesgo.

Los pesos representan la influencia que cada feature adquiere dentro de la predicción. Al comenzar el entrenamiento todavía no se conocen los valores adecuados; estos serán ajustados de forma iterativa mediante descenso de gradiente.

El valor “z” todavía no corresponde a la clasificación final, por lo que primero debe pasar por la función de activación, en este caso sigmoide.

C. Función sigmoide

El objetivo de esta función es pasar nuestros resultados a cualquier valor entre 0 y 1.

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

De esta manera, la combinación lineal de las características y pesos puede utilizarse como una probabilidad para el problema de clasificación binaria. Esta es la razón por la que previamente se transformó Result a las clases 0 y 1.

D. Función de costo

Una vez obtenida la predicción, se requiere medir qué tan diferente es respecto a la clase real. Para la regresión logística se utilizará entropía cruzada o Cross-Entropy como función de costo:

$$J = -\frac{1}{m} \sum_{i=1}^m [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

donde y_i representa la clase real y $\hat{y}_i$ la probabilidad calculada por el modelo.

El costo permite resumir el error producido por las predicciones durante el entrenamiento. Una predicción cercana a la clase correcta produce una pérdida menor; mientras que una predicción alejada del valor real aumenta el costo.

El objetivo del entrenamiento será reducirlo progresivamente modificando los parámetros del modelo. Cross-Entropy forma parte de las funciones de costo trabajadas específicamente para regresión logística en el módulo.

E. Descenso de gradiente

Para modificar los pesos se utilizará descenso de gradiente. Su función es determinar en qué dirección deben ajustarse los parámetros para disminuir el valor de la función de costo.

En cada iteración se calculan las predicciones utilizando los pesos actuales, se obtiene el error y posteriormente se calcula el gradiente. Los parámetros se actualizan en dirección contraria al gradiente:

$$w = w - \alpha dw$$

$$b = b - \alpha db$$

donde Alpha representa el learning rate o tasa de aprendizaje y controla la magnitud del cambio aplicado a los parámetros en cada actualización. Un valor demasiado grande puede generar cambios excesivos, mientras que uno demasiado pequeño puede requerir una mayor cantidad de iteraciones para disminuir el costo. Para esta primera implementación se utilizó una tasa de aprendizaje de 0.01, cuyo comportamiento se evaluó mediante la evolución de la función de costo en Train y Validation.

F. Proceso de entrenamiento

Con los componentes anteriores, el entrenamiento seguirá una secuencia iterativa. Primero se inicializan los pesos y el sesgo; posteriormente se generan las predicciones sobre el conjunto de entrenamiento, se calcula el costo y se obtienen los gradientes necesarios para actualizar los parámetros. Este procedimiento se repite durante un número determinado de épocas:

Predicción → Costo → Gradiente → Actualización → Nueva predicción

A medida que avanzan las épocas se espera que los parámetros encuentren valores que reduzcan el costo del modelo sobre los datos de entrenamiento.

G. Predicción de clases

La función sigmoide devuelve una probabilidad y no directamente una clase. Para convertir dicha salida en una predicción final se utilizará un umbral de 0.5:

$$\hat{y} = \begin{cases} 1, & \sigma(z) \geq 0.5 \\ 0, & \sigma(z) < 0.5 \end{cases}$$

Así, cada nueva instancia primero genera una probabilidad y posteriormente es asignada a una de las dos clases. La predicción es comparada con el valor real de Result para calcular el desempeño del clasificador.

IV. RESULTADOS DEL MODELO DE CLASIFICACIÓN

A. Configuración del modelo

Para realizar la primera prueba se entrenó la regresión logística con una tasa de aprendizaje de 0.01 durante 3000 épocas. Los pesos fueron inicializados en cero y se actualizaron utilizando Batch Gradient Descent sobre el conjunto de entrenamiento. Para convertir las probabilidades obtenidas por la función sigmoide en una clase se utilizó un umbral de 0.5.

B. Comportamiento de la función de costo

Durante las 3000 épocas se registró el valor de Cross-Entropy tanto para Train como para Validation. La evolución obtenida se presenta en la Figura 2.




Fig. 2. Evolución de Cross-Entropy Loss en los conjuntos de entrenamiento y validación.

En la gráfica se observa una disminución progresiva del costo conforme avanza el entrenamiento. Al inicio ambas curvas presentan valores cercanos a 0.69, mientras que hacia las últimas épocas se aproximan a 0.21. La reducción es más

rápida durante las primeras iteraciones y posteriormente los cambios comienzan a ser menores.

Otro punto que se observa es que las curvas de entrenamiento y validación permanecen muy próximas durante prácticamente todo el proceso. No aparece una separación creciente entre ambas, aun después de continuar actualizando los parámetros hasta la época 3000. Conforme avanzaron las épocas, ambos costos disminuyeron siguiendo una trayectoria muy similar. Hacia el final del entrenamiento los cambios también son cada vez menores, por lo que continuar aumentando el número de épocas produciría, al menos con esta configuración, reducciones cada vez más pequeñas en la función de costo.

C. Resultados en Train, Validation y Test

Después de completar el entrenamiento se calcularon Cross-Entropy Loss, Accuracy y Precision para cada uno de los tres conjuntos.

TABLA III. RESULTADOS DEL MODELO

Conjunto	Cross-Entropy	Accuracy	Precision
Train	0.2123	92.02 %	92.11 %
Validation	0.2076	92.67 %	91.89 %
Test	0.2055	92.40 %	92.30 %

Los tres conjuntos presentan resultados similares. La diferencia entre el valor más alto y el más bajo es menor a un punto porcentual, por lo que el rendimiento se mantuvo estable al evaluar observaciones que no fueron utilizadas para modificar los pesos.

La misma tendencia aparece en Precision. En este cálculo se consideró Result = 1 como la clase positiva. La cercanía entre estos valores indica que el modelo mantiene un comportamiento semejante en los tres subconjuntos y que su resultado no depende únicamente de las observaciones utilizadas durante el entrenamiento.

D. Matriz de confusión

Para observar con mayor detalle las clasificaciones realizadas sobre los datos de prueba se generó una matriz de confusión. Esta herramienta permite separar las predicciones correctas e incorrectas de acuerdo con la clase real y la clase asignada por el modelo.




Fig. 3. Matriz de confusión del conjunto Test para el modelo de regresión logística.

La mayor parte de las observaciones se concentra en la diagonal principal de la matriz. El modelo clasificó correctamente 916 observaciones de la clase 0 y 1,127 de la clase 1, mientras que 94 observaciones de clase 0 fueron asignadas a la clase 1 y 74 de clase 1 fueron clasificadas como 0. En conjunto, se obtuvieron 2,043 clasificaciones correctas y 168 incorrectas dentro de Test. Los errores aparecen en ambas clases y ninguno de los dos tipos domina ampliamente sobre el otro, lo cual es consistente con la Accuracy de 92.40 % obtenida para este conjunto.

E. Distribución de las probabilidades obtenidas

Además de la clase final, la función sigmoide produce un valor entre 0 y 1 para cada observación.




Fig. 4. Distribución de las probabilidades predichas para el conjunto Test.

La distribución muestra una separación clara entre ambas clases. Las observaciones cuya clase real es 0 se concentran principalmente en probabilidades cercanas a cero, mientras que las observaciones de clase 1 aparecen con mayor frecuencia en valores próximos a uno. Esto indica que, en una parte importante de los casos, el modelo asigna probabilidades coherentes con la clase real de cada observación.

También existe una zona de superposición entre ambas distribuciones. Algunas observaciones de clase 0 reciben probabilidades mayores y algunas observaciones de clase 1 presentan valores menores. Esta superposición ayuda a explicar los errores observados en la matriz de confusión, ya que las instancias que cruzan el umbral de 0.5 pueden ser asignadas a una clase distinta de la real.

La línea ubicada en 0.5 representa el criterio utilizado para transformar la probabilidad en una predicción final. Los valores inferiores a este umbral son asignados a la clase 0 y los valores iguales o superiores a 0.5 se clasifican como clase 1. Este procedimiento corresponde directamente a la forma en que el modelo realiza sus predicciones en el código.

F. Diagnóstico del modelo

El comportamiento del modelo se analizó considerando de manera conjunta la evolución de la función de costo y los resultados obtenidos en Train, Validation y Test. La Accuracy y la Precision se mantienen muy cercanas entre los tres conjuntos, y la diferencia observada entre ellos es pequeña.

La curva de costo también presenta un comportamiento similar en Train y Validation durante las 3000 épocas. No se observa una separación progresiva entre ambas, lo que indica que el modelo no presenta una ventaja importante sobre los datos utilizados directamente durante el entrenamiento.

Con base en este comportamiento, la varianza se considera baja, ya que el desempeño del modelo se mantiene estable al pasar de Train a Validation y Test. Tampoco se observan señales claras de overfitting, debido a que el rendimiento sobre los datos de entrenamiento no es considerablemente superior al obtenido en los otros conjuntos.

Por otra parte, el modelo alcanza una Accuracy superior al 92 % en los tres subconjuntos, aunque todavía conserva una proporción de clasificaciones incorrectas. Por ello, el bias se considera bajo. El modelo logra identificar una parte importante de los patrones disponibles en las características del dataset, pero no alcanza una clasificación completamente correcta de las observaciones.

Considerando ambos elementos, esta primera implementación presenta un ajuste adecuado. No se observa un desempeño bajo generalizado que indique underfitting, ni una diferencia marcada entre entrenamiento y validación que sugiera overfitting.

Este diagnóstico de bias, varianza y fitting es cualitativo y se basa en el comportamiento observado en las métricas y en las curvas de costo.

G. Predicciones individuales

TABLA IV. EJEMPLOS DE PREDICCIONES INDIVIDUALES

Probabilidad	Predicción	Clase real	Resultado
0.9604	1	1	Correcta
0.7773	1	0	Incorrecta
0.0106	0	0	Correcta
0.0233	0	0	Correcta
0.8515	1	1	Correcta

Los ejemplos permiten observar de manera directa el proceso final del clasificador. Las probabilidades cercanas a los extremos tienden a producir decisiones más claras, mientras que aquellas próximas al umbral de 0.5 pueden representar casos en los que la clasificación resulta menos definida.

V. CONCLUSIONES

Con esta evaluación se completa el análisis del modelo de regresión logística implementado manualmente. Los resultados obtenidos muestran un comportamiento estable entre Train, Validation y Test, por lo que el modelo puede considerarse adecuado como primera implementación de clasificación sin framework.

La implementación permitió aplicar los componentes revisados durante el módulo: función de hipótesis, función sigmoide, Cross-Entropy y descenso de gradiente. La Accuracy fue de 92.02 % en Train, 92.67 % en Validation y 92.40 % en Test. Al comparar estos resultados con la evolución de la función de costo, concluimos de manera cualitativa que el modelo presenta bias bajo, varianza baja y un ajuste adecuado.

REFERENCIAS

- [1] R. M. Mohammad and L. McCluskey, "Phishing Websites," *UCI Machine Learning Repository*, 2012, doi: 10.24432/C51W2X.
- [2] R. M. Mohammad, F. Thabtah, and L. McCluskey, "An assessment of features related to phishing websites using an automated technique," in *Proc. 2012 Int. Conf. Internet Technology and Secured Transactions*, 2012, pp. 492-497.