

Predicción del precio de diamantes mediante Random Forest y ajuste progresivo de hiperparámetros

Aron Cortez Villafuerte

Inteligencia artificial avanzada para la ciencia de datos I
Instituto Tecnológico y de Estudios Superiores de Monterrey
Querétaro, México

Abstract—Se implementó un modelo de Random Forest con scikit-learn para estimar el precio de diamantes a partir de sus características físicas y categóricas. El conjunto Diamonds se preparó eliminando 20 filas con dimensiones iguales a cero y 145 duplicados posteriores, con lo que quedaron 53,775 observaciones. Las variables categóricas se representaron mediante One-Hot Encoding y se obtuvieron 26 features. Los datos se dividieron en Train, Validation y Test con proporciones de 60/20/20 y semilla 42. A partir de un modelo base de 50 árboles y profundidad 10, se estudió por separado el efecto del número de árboles y de la profundidad, seguido de un refinamiento local. La configuración de 200 árboles y profundidad 18 obtuvo el menor MSE de Validation entre los candidatos evaluados. Una vez cerrada la selección, el MSE de Test disminuyó de 527,360.1483 a 345,534.1000 USD², una reducción de 34.4785 %, mientras que R² aumentó de 0.9670 a 0.9783. El diagnóstico cualitativo final fue de bias bajo, varianza media y fitting adecuado. La búsqueda realizada es limitada y no garantiza un óptimo global.

Keywords—Random Forest, regresión, Diamonds, bagging, ajuste de hiperparámetros, MSE, R², Train/Validation/Test.

I. INTRODUCCIÓN

El aprendizaje automático permite analizar conjuntos de datos con el objetivo de identificar patrones y generar predicciones a partir de la información disponible. Dentro del aprendizaje supervisado, los problemas de regresión buscan estimar un valor numérico a partir de las características de cada observación. En este proyecto se estudia la estimación del precio de diamantes, utilizando información relacionada con su peso, calidad y dimensiones.

El conjunto de datos contiene distintas características físicas y categóricas de cada diamante, mientras que la variable que se desea predecir corresponde a su precio. El uso de un modelo de este tipo permite estudiar la relación existente entre las características de un diamante y su valor, y posteriormente generar estimaciones de precio para nuevas instancias.

El objetivo del trabajo fue implementar un modelo de Random Forest mediante la biblioteca scikit-learn y analizar cómo cambia su desempeño al modificar el número de árboles y su profundidad máxima. Además de comparar el modelo base con el ajustado, se buscó interpretar los resultados de entrenamiento, validación y prueba para discutir el sesgo, la varianza y el nivel de ajuste del modelo.

II. DESCRIPCIÓN Y PREPARACIÓN DE LOS DATOS

A. Fuente y estructura del conjunto de datos

El conjunto de datos utilizado corresponde a Diamonds. Se trabajó con el archivo diamonds.csv del repositorio público seaborn-data de Michael Waskom [1]. En este caso, cada fila reúne las características de un diamante y el precio registrado para esa observación. El problema consiste en utilizar esas características para estimar price mediante un modelo de regresión.

La lectura del archivo permitió identificar 53,940 instancias y 10 columnas. Nueve corresponden a las variables predictoras: carat, cut, color, clarity, depth, table, x, y y z; la columna restante, price, es la variable objetivo. El número de fila que aparece al cargar los datos únicamente indica su posición dentro del archivo y no se utiliza como feature. El script conserva expresamente las diez columnas del problema, por lo que tampoco incorpora posibles columnas de índice del CSV.

Diamonds combina seis mediciones numéricas con tres características categóricas. carat representa el peso en quilates; depth y table describen proporciones del diamante, mientras que x, y y z corresponden a su longitud, ancho y profundidad en milímetros. Por su parte, cut describe cinco niveles de calidad del corte; color contiene siete grados, de D a J; y clarity representa ocho niveles de claridad [2]. Estas categorías tienen un orden de calidad, aunque sus etiquetas no expresan una distancia numérica entre niveles.

Aunque price se almacena como un número entero, representa una cantidad monetaria que se desea estimar. No se convierte en categorías de precio alto o bajo. También conviene distinguir la columna y, que mide el ancho del diamante, de la notación utilizada para representar la variable objetivo; en este problema, el target siempre corresponde a price.

B. Revisión inicial y limpieza

Primero se revisaron la estructura del archivo, los tipos de datos y la presencia de valores faltantes. Las diez columnas se cargaron correctamente y no se encontraron valores nulos. Sin embargo, esta comprobación por sí sola no garantiza que todas las mediciones sean válidas. Al revisar los valores mínimos de x, y y z se observaron dimensiones iguales a cero, que no corresponden a una medida física válida de un diamante.

Se encontraron 8 valores iguales a cero en x, 7 en y y 20 en z. Estas cantidades no se suman porque algunas observaciones presentan el problema en más de una columna. En total, 20 filas contienen al menos una dimensión igual a cero. Se excluyeron esas filas antes de preparar los conjuntos de entrenamiento y evaluación; no se sustituyeron las medidas por promedios, ya que el archivo no aporta información para recuperar su valor real.

La revisión de las diez columnas también identificó 146 filas que repetían exactamente un registro anterior. Después de excluir las dimensiones iguales a cero quedaron 145 repeticiones completas. Se conservó una sola observación por combinación de las diez variables, para evitar que copias idénticas pudieran quedar en entrenamiento y evaluación. Esta decisión no demuestra que las filas correspondan al mismo diamante, pues no existe un identificador; establece un criterio de preparación para este experimento. Tras aplicar ambos criterios quedaron 53,775 instancias.

TABLA I
RESUMEN DEL DATASET Y SU PREPARACIÓN

Elemento	Resultado
Filas iniciales	53,940
Filas con dimensiones cero	20
Duplicados eliminados después de ceros	145
Filas finales	53,775
Variables originales	9
Variables tras One-Hot	26
Target	price (USD)
Train	32,265
Validation	10,755
Test	10,755

También se observaron máximos de 58.90 mm en y y 31.80 mm en z, alejados de sus respectivos terceros cuartiles de 6.54 y 4.04 mm. Son valores que requieren atención al interpretar los resultados, pero no se eliminaron mediante un umbral arbitrario. La limpieza se limitó a las dimensiones iguales a cero y a las repeticiones completas; no se aplicaron transformaciones adicionales sobre las mediciones ni sobre el precio.




Fig. 1. Distribución de price en las 53,775 observaciones del dataset limpio. Esta figura descriptiva se generó al terminar el experimento.

La Figura 1 muestra una mayor concentración de diamantes en los precios bajos y una disminución de la frecuencia hacia los precios más altos. Se mantuvo price en su escala original, de modo que las predicciones puedan interpretarse directamente como precios en dólares estadounidenses. La distribución completa se graficó al final y no se utilizó para seleccionar hiperparámetros.

C. División y preparación de las variables

Para evaluar el comportamiento del modelo sobre observaciones diferentes a las utilizadas durante su entrenamiento, el conjunto limpio se dividió en tres subconjuntos. Después de aleatorizar las filas con una semilla fija de 42, se asignó el 60 % a Train, el 20 % a Validation y el 20 % a Test. Sobre las 53,775 instancias disponibles, esto dio lugar a 32,265 observaciones de entrenamiento, 10,755 de validación y 10,755 de prueba.

Cada observación quedó asociada a un solo subconjunto y las características conservaron la correspondencia con su precio real después de aleatorizar los índices. La semilla permite repetir la misma división, de manera que las diferencias observadas entre configuraciones no se deban a cambios en los datos utilizados para entrenar y evaluar.

Las columnas cut, color y clarity contienen texto y requieren una representación numérica para incorporarlas al modelo. Se utilizó One-Hot Encoding. La transformación crea una columna por categoría: el valor 1 indica que la observación pertenece a esa categoría y el valor 0 indica que no pertenece a ella. Por ejemplo, una observación con cut igual a Ideal tiene cut_Ideal = 1 y cero en las otras cuatro columnas del corte.

Aunque estas variables tienen un orden de calidad, se optó por representarlas mediante indicadores separados. Así no se asignan números consecutivos que puedan interpretarse como diferencias de igual magnitud entre niveles. Las cinco categorías de cut, las siete de color y las ocho de clarity generan 20 columnas binarias. Al conservar además carat, depth, table, x, y y z, la matriz X queda formada por 26 características numéricas. price se separa antes de la codificación y no participa entre las entradas del modelo.

La separación se realizó antes de definir las columnas de One-Hot. Train estableció la estructura de la matriz de entrada y Validation se alineó con esas mismas columnas. Test permaneció reservado durante la búsqueda; su codificación y sus predicciones se realizaron únicamente después de seleccionar la configuración final. Esta organización permitió utilizar Train para construir los modelos y Validation para compararlos, conservando Test como evaluación final del experimento.

III. MODELO DE RANDOM FOREST Y EVALUACIÓN

A. Árboles de decisión y bagging

La implementación se desarrolló con la clase RandomForestRegressor de scikit-learn [3]. Al utilizar un algoritmo disponible en la biblioteca, el enfoque del trabajo se centró en la preparación de los datos, la configuración del modelo y el análisis de su comportamiento sobre los distintos conjuntos.

Un árbol de regresión divide las observaciones mediante condiciones sobre sus características. Por ejemplo, una división puede separar los diamantes según su peso. Al continuar estas divisiones, el árbol forma grupos cada vez más específicos y utiliza los precios de entrenamiento de cada grupo para generar una estimación. Permitir más niveles hace posible representar relaciones más detalladas, aunque también puede aumentar la adaptación a particularidades de Train.

Random Forest combina múltiples árboles de decisión mediante un ensamble. De acuerdo con el enfoque de bagging presentado en MachineLearning.pdf [4], se construyen distintas muestras de entrenamiento mediante muestreo con

reemplazo: una observación puede seleccionarse varias veces para una muestra y quedar fuera de otra. Cada árbol se entrena sobre su muestra y , en regresión, el bosque promedia las predicciones numéricas de sus árboles. Este promedio ayuda a reducir la variabilidad que podría presentar un árbol individual, pero no garantiza la ausencia de sobreajuste.

El material del curso también describe la selección aleatoria de características. En el script se conservaron los valores predeterminados de la clase, incluido `max_features = 1.0`, que considera todas las features al buscar una división [3]. Por ello, la explicación de esta implementación se apoya principalmente en las muestras bootstrap y el promedio de predicciones, sin atribuirle un subconjunto reducido de variables que no se configuró.

B. Configuración e implementación

La configuración inicial utilizada fue de 50 árboles con una profundidad máxima de 10 y una semilla de 42. Esta primera combinación se tomó como modelo base y permitió establecer un punto de comparación antes de modificar los hiperparámetros. `n_estimators` determina cuántos árboles forman el bosque, mientras que `max_depth` limita el número de niveles que puede alcanzar cada árbol.

Todas las configuraciones se entrenaron utilizando el mismo conjunto Train. La semilla 42 también se mantuvo en los modelos para hacer reproducible la aleatoriedad del bosque. Las features y price conservaron su escala; no se aplicó normalización, ya que los árboles realizan divisiones por umbrales sobre cada variable y no necesitan comparar distancias entre variables.

C. Métricas de evaluación

El desempeño del modelo se evaluó utilizando Mean Squared Error (MSE) y el coeficiente de determinación R^2 . Ambas métricas permiten analizar el problema desde perspectivas diferentes: MSE refleja la magnitud del error producido por las predicciones, mientras que R^2 permite comparar qué tan bien el modelo representa la variación presente en la variable objetivo.

$$MSE = (1/n) \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

En esta expresión, y_i es el precio real, $\hat{y}_i$ es el precio predicho y n es el número de observaciones evaluadas. Al elevar las diferencias al cuadrado, los errores grandes tienen un mayor peso. Como price está expresado en dólares, MSE queda en USD²; por ello, un valor de cientos de miles no representa directamente un error de cientos de miles de dólares por diamante.

$$R^2 = 1 - \sum_{i=1}^n (y_i - \hat{y}_i)^2 / \sum_{i=1}^n (y_i - \bar{y})^2$$

Aquí, $\bar{y}$ corresponde al precio medio del conjunto evaluado. Un R^2 cercano a 1 indica que el error es pequeño respecto a la variación de los precios de ese conjunto. No debe interpretarse como un porcentaje de predicciones exactamente correctas. El código calculó ambas métricas mediante `mean_squared_error` y `r2_score`, manteniendo el mismo procedimiento para todos los modelos.

IV. MODELO BASE Y BÚSQUEDA PROGRESIVA

A. Resultados del modelo base

La primera ejecución de Random Forest se realizó utilizando 50 árboles y profundidad máxima de 10. Después del entrenamiento se evaluaron Train y Validation para establecer su comportamiento inicial antes de modificar los hiperparámetros. Los resultados de Test se incorporaron únicamente en la comparación final.

TABLA II
MODELO BASE: 50 ÁRBOLES Y PROFUNDIDAD 10

Conjunto	MSE (USD ²)	R ²
Train	371,060.8940	0.9764
Validation	482,457.5787	0.9703

El modelo obtuvo un R^2 de 0.9764 en Train y 0.9703 en Validation. Aunque el MSE aumentó al pasar a Validation, la diferencia de R^2 entre ambos conjuntos fue pequeña, de aproximadamente 0.0061. Como diagnóstico inicial, este comportamiento es compatible con bias bajo, varianza baja y ajuste adecuado. Sin embargo, el error de Validation todavía dejaba margen para evaluar si una configuración distinta podía mejorar las predicciones.

B. Estrategia de ajuste

El ajuste se realizó mediante una búsqueda progresiva limitada. Primero se compararon 50, 100 y 200 árboles manteniendo profundidad 10. Después se fijaron 100 árboles y se probaron profundidades de 5, 10, 15 y 20. Así fue posible estudiar por separado el efecto de cada hiperparámetro, conservando el otro constante.

A partir de la mejor profundidad de esa segunda etapa se evaluaron sus vecinos a una distancia de dos niveles. Una vez identificada la mejor profundidad local, se volvieron a comparar 50, 100 y 200 árboles en esa profundidad. Cada combinación distinta se entrenó una sola vez durante la búsqueda y se guardaron sus resultados para reutilizarlos cuando aparecía en otra etapa.

El criterio de selección fue el menor MSE de Validation entre todos los candidatos evaluados, incluido el modelo base. R^2 se utilizó para interpretar el desempeño. En caso de un empate exacto en MSE, el script favoreció una menor profundidad y, después, un menor número de árboles. Test no intervino en estas decisiones.

C. Efecto del número de árboles

TABLA III
NÚMERO DE ÁRBOLES CON PROFUNDIDAD 10

Árb.	Train MSE	Train R ²	Val. MSE	Val. R ²
50	371,060.89	0.9764	482,457.58	0.9703
100	371,267.87	0.9764	481,280.63	0.9704
200	369,857.15	0.9765	480,572.70	0.9704

MSE en USD². Val. corresponde a Validation; los valores de MSE se muestran con dos decimales.




Fig. 2. MSE de Validation al variar el número de árboles con profundidad máxima de 10.

El aumento de 50 a 100 árboles redujo el MSE de Validation de 482,457.5787 a 481,280.6297 USD². Al utilizar 200 árboles, el valor descendió a 480,572.6956 USD². Aunque la tendencia fue favorable, la reducción total entre 50 y 200 árboles fue de aproximadamente 0.39 %, y R^2 se mantuvo alrededor de 0.9704.

La Figura 2 permite observar que las diferencias son pequeñas cuando se conserva la profundidad 10. Por lo tanto, agregar árboles por sí solo no produjo un cambio importante en la capacidad predictiva de esta configuración. Este resultado motivó revisar el efecto de permitir árboles con más niveles.

D. Efecto de la profundidad máxima

TABLA IV
PROFUNDIDAD MÁXIMA CON 100 ÁRBOLES

Prof.	Train MSE	Train R^2	Val. MSE	Val. R^2
5	1,271,166.99	0.9192	1,303,227.68	0.9198
10	371,267.87	0.9764	481,280.63	0.9704
15	105,772.45	0.9933	316,618.76	0.9805
20	49,333.82	0.9969	315,764.75	0.9806

MSE en USD². Val. corresponde a Validation; los valores de MSE se muestran con dos decimales.




Fig. 3. R^2 de Train y Validation al variar la profundidad máxima con 100 árboles.

La profundidad produjo un cambio considerablemente mayor que el número de árboles. Con profundidad 5, Train y

Validation presentaron R^2 cercanos a 0.919 y errores elevados frente a las demás configuraciones. La cercanía entre ambos resultados no basta para considerar que un modelo es mejor: en este caso, los dos conjuntos se beneficiaron de permitir una estructura más compleja.

Al pasar de profundidad 10 a 15, el MSE de Validation disminuyó de 481,280.6297 a 316,618.7607 USD², una reducción aproximada de 34.21 %. Sin embargo, el cambio de 15 a 20 sólo lo redujo a 315,764.7489 USD², alrededor de 0.27 % adicional. En ese último paso, el R^2 de Train aumentó de 0.9933 a 0.9969, mientras que Validation cambió de 0.9805 a 0.9806.

La Figura 3 muestra que, a partir de esa región, Train continuó mejorando con mayor claridad que Validation. Esto sugiere que los niveles adicionales permitieron una adaptación más fuerte al entrenamiento, mientras que el beneficio fuera de Train comenzó a estabilizarse. La profundidad 20 obtuvo el menor MSE de Validation en esta etapa y se utilizó como centro del refinamiento local.

E. Refinamiento local y selección final

El refinamiento comparó profundidades 18, 20 y 22 con 100 árboles. Entre esas opciones, profundidad 18 presentó el menor MSE de Validation: 314,550.4312 USD². En cambio, las profundidades 20 y 22 alcanzaron 315,764.7489 y 315,675.4244 USD². Aunque ambas redujeron más el error de Train, no mejoraron el resultado de Validation respecto a profundidad 18.

TABLA V
CANDIDATOS DEL REFINAMIENTO LOCAL

Árb. prof.	Train MSE	Train R^2	Val. MSE	Val. R^2
100 / 18	60,403.22	0.9962	314,550.43	0.9806
100 / 20	49,333.82	0.9969	315,764.75	0.9806
100 / 22	45,120.53	0.9971	315,675.42	0.9806
50 / 18	62,260.09	0.9960	317,707.42	0.9804
200 / 18	59,898.50	0.9962	313,037.63	0.9807

MSE en USD². Se muestra una sola vez la configuración de 100 árboles y profundidad 18, compartida por las dos fases del refinamiento.




Fig. 4. MSE de Validation para los candidatos del refinamiento local y la comparación de árboles a profundidad 18.

Después se mantuvo profundidad 18 y se compararon nuevamente 50, 100 y 200 árboles. El MSE de Validation pasó de 317,707.4159 a 314,550.4312 y finalmente a 313,037.6322 USD². Las reducciones fueron de aproximadamente 0.99 %

entre 50 y 100 árboles y 0.48 % entre 100 y 200. Al igual que en el primer experimento, el beneficio de agregar árboles fue menor que el observado al modificar la profundidad.

La configuración seleccionada fue de 200 árboles y profundidad máxima de 18, ya que obtuvo el menor MSE de Validation entre las diez combinaciones distintas evaluadas. La búsqueda encontró una opción favorable dentro de los candidatos probados, pero no garantiza un óptimo global. En particular, 200 fue el mayor número de árboles considerado y no se evaluaron todas las combinaciones posibles de ambos hiperparámetros.

V. COMPARACIÓN FINAL DEL MODELO BASE Y AJUSTADO

A. Evaluación con Train, Validation y Test

Una vez cerrada la selección, se entrenaron nuevamente el modelo base y el ajustado utilizando únicamente los mismos datos de Train y la semilla 42. No se unieron Train y Validation, de modo que la comparación final mantuvo las mismas condiciones de entrenamiento. Después se preparó Test con las columnas de One-Hot definidas por Train y se calcularon sus predicciones.

TABLA VI
COMPARACIÓN FINAL: BASE Y AJUSTADO

Conjunto	MSE base	MSE ajustado
Train	371,060.8940	59,898.4961
Validation	482,457.5787	313,037.6322
Test	527,360.1483	345,534.1000

TABLA VI (CONT.)
R² Y REDUCCIÓN RELATIVA DEL MSE

Conjunto	R ² base	R ² ajust.	Reducción MSE (%)
Train	0.9764	0.9962	83.8575
Validation	0.9703	0.9807	35.1160
Test	0.9670	0.9783	34.4785

Base: 50 árboles, profundidad 10. Ajustado: 200 árboles, profundidad 18. MSE en USD². Reducción = $100 \times (\text{MSE base} - \text{MSE ajustado}) / \text{MSE base}$.

El ajuste redujo el MSE en los tres subconjuntos. Train presentó la mayor reducción, de 83.8575 %, mientras que Validation y Test alcanzaron 35.1160 % y 34.4785 %, respectivamente. La cercanía entre estas dos últimas cifras muestra que la mejora observada durante la selección también se conservó en el conjunto reservado de prueba.

En Test, el MSE disminuyó de 527,360.1483 a 345,534.1000 USD² y R² aumentó de 0.9670 a 0.9783. En Validation, R² pasó de 0.9703 a 0.9807, mientras que en Train pasó de 0.9764 a 0.9962. Por tanto, el resultado favorable no se limitó a una reducción del error sobre los datos utilizados para construir los árboles.

B. Relación entre precio real y precio predicho

Para complementar la evaluación numérica, las Figuras 5 y 6 comparan los precios reales de Test con las predicciones de ambos modelos. Las dos gráficas utilizan las mismas observaciones y los mismos límites en los ejes. La línea diagonal representa la predicción ideal, donde el precio estimado coincide con el real.




Fig. 5. Precio real frente al precio predicho por el modelo base en Test. Esta evaluación se realizó después de seleccionar los hiperparámetros.

La mayor concentración de observaciones alrededor de la referencia ideal indica que el modelo base captura de manera adecuada la relación general entre las características de los diamantes y su precio. Sin embargo, la dispersión aumenta conforme se alcanzan precios más altos, por lo que la precisión de las estimaciones no es uniforme en todo el rango de price.




Fig. 6. Precio real frente al precio predicho por el modelo ajustado en Test, con la misma escala que la Figura 5.

Después del ajuste, las predicciones se concentran de forma más cercana a la línea ideal en buena parte del rango de precios. La dispersión sigue siendo mayor en los valores más altos, por lo que el modelo todavía presenta errores individuales relevantes en algunos diamantes. Esta diferencia es consistente con la reducción del MSE observada en la evaluación final y muestra que el ajuste permitió mejorar las

estimaciones sin modificar el patrón general de las predicciones.

C. Comparación del error y del coeficiente R^2




Fig. 7. Comparación del MSE entre el modelo base y el ajustado en los tres subconjuntos.

La reducción del error se mantiene en los tres conjuntos, por lo que la mejora no se concentra únicamente en los datos de entrenamiento. El cambio es especialmente relevante en Validation y Test, donde el modelo ajustado conserva una disminución clara del MSE frente a la configuración inicial.




Fig. 8. Comparación de R^2 entre el modelo base y el ajustado. Las etiquetas permiten distinguir las diferencias entre valores cercanos a 1.

Al mismo tiempo, la separación entre Train y los conjuntos reservados es mayor en el modelo ajustado. La diferencia de R^2 entre Train y Validation aumentó de aproximadamente 0.0061 a 0.0155. Este comportamiento es compatible con una mayor adaptación al entrenamiento al incrementar la profundidad. Sin embargo, en esta partición, Validation y Test también mejoraron frente al modelo base.

VI. DIAGNÓSTICO Y ALCANCE DE LOS RESULTADOS

El diagnóstico de bias, varianza y fitting se realizó de forma cualitativa, a partir de la comparación de errores y de la evolución del desempeño al modificar la complejidad del modelo. Estas categorías siguen el análisis solicitado en el material del curso [4]; no representan una medición formal de la descomposición matemática del error ni de la variabilidad entre múltiples entrenamientos.

El bias se considera bajo porque el modelo ajustado alcanzó un R^2 de 0.9962 en Train y un error considerablemente menor que el modelo base. Esto es compatible con una capacidad suficiente para representar las relaciones disponibles en el

conjunto de entrenamiento. No se observa el desempeño bajo generalizado que sugeriría un modelo demasiado simple para estos datos.

La varianza se considera media. La brecha entre Train y Validation aumentó y el estudio de profundidad mostró que el entrenamiento continuó mejorando cuando Validation ya estaba cerca de estabilizarse. Son indicios de una mayor adaptación a Train, aunque una sola división de datos no permite medir directamente cuánto cambiaría el modelo si se entrenara con otras muestras.

El fitting se considera adecuado porque el incremento de complejidad produjo mejoras tanto en Validation como en Test. La mayor brecha no anuló el beneficio del ajuste en los datos reservados. Aun así, estos resultados no permiten afirmar que el sobreajuste esté ausente: el modelo conserva una ventaja importante en Train y las profundidades 20 y 22 no mejoraron Validation respecto a 18 durante el refinamiento.

El alcance de esta conclusión se limita al dataset preparado, la partición con semilla 42 y las configuraciones evaluadas. La búsqueda progresiva orientó el ajuste hacia una región favorable sin explorar todas las opciones, y las diferencias pequeñas entre candidatos deben leerse dentro de ese alcance. El conjunto Test aportó una comprobación final reservada, pero sigue perteneciendo al mismo dataset.

VII. CONCLUSIONES

La implementación de Random Forest permitió estimar el precio de diamantes a partir de 26 features obtenidas después de limpiar y codificar Diamonds. El análisis separado de hiperparámetros mostró que aumentar la profundidad tuvo un efecto mayor que incrementar únicamente el número de árboles. A partir de profundidad 15, las mejoras de Validation se hicieron pequeñas, mientras que Train continuó beneficiándose de una mayor complejidad.

El refinamiento local permitió seleccionar 200 árboles y profundidad 18 por su menor MSE de Validation. Frente al modelo base de 50 árboles y profundidad 10, el MSE de Test se redujo 34.4785 % y R^2 pasó de 0.9670 a 0.9783. La mejora se conservó en el conjunto reservado, aunque también aumentó la separación respecto a Train. Por ello, el diagnóstico cualitativo final fue de bias bajo, varianza media y fitting adecuado. Esta configuración fue la mejor dentro de la búsqueda realizada, sin que ello implique haber encontrado el óptimo global.

REFERENCIAS

- [1] M. Waskom, "diamonds.csv", repositorio público seaborn-data, GitHub. [En línea].
- [2] ggplot2, "Prices of over 50,000 round cut diamonds", documentación del conjunto Diamonds. [En línea].
- [3] scikit-learn, "RandomForestRegressor", documentación oficial de la biblioteca. [En línea].
- [4] "MachineLearning.pdf", material del módulo, secciones 2.4 y 2.7.2, pp. 9 y 23-25, documento proporcionado para el curso.